

ЧАСТЬ 2. Метрики регрессии: RMSE, MAE и R^2

Цель: уметь не просто посчитать три формулы, а объяснить, почему две метрики могут дать противоположный вердикт о том, какая модель лучше, и что на самом деле означает отрицательный R^2 .

1. Метрика оценки vs функция потерь — важное разграничение

Функция потерь (*loss*) — то, что **минимизирует оптимизатор во время обучения**. Метрика — то, чем **вы оцениваете готовую модель после обучения**, часто человеку для интерпретации. Они могут совпадать (модель, обученная минимизировать MSE, естественно, сравнивается по RMSE), а могут не совпадать (модель обучена на MSE, но бизнесу нужен MAE, потому что он устойчивее к выбросам). Путаница этих двух ролей — частый повод для ошибок в дизайне пайплайна.

2. MAE (Mean Absolute Error)

$$\text{MAE} = (1/n) \cdot \sum |y_i - \hat{y}_i|$$

Свойства:

- измеряется в тех же единицах, что и таргет (рубли, секунды, штуки) — легко объяснить бизнесу;
 - **линейный штраф**: ошибка в 10 единиц штрафуеться ровно в 10 раз сильнее ошибки в 1 единицу — не больше и не меньше;
 - **устойчива к выбросам** — один аномально большой промах не «взрывает» метрику, а просто вносит пропорциональный вклад;
 - математический факт (полезно знать для собеседования): значение, минимизирующее MAE на выборке — это **медиана**, а не среднее. Поэтому модель, обученная на MAE-подобной функции потерь, стремится предсказывать «типичное» значение, устойчивое к перекосу распределения.
-

3. RMSE (Root Mean Squared Error) и MSE

$$MSE = (1/n) \cdot \sum (y_i - \hat{y}_i)^2$$

$$RMSE = \sqrt{MSE}$$

Свойства:

- *RMSE*, как и *MAE*, возвращается в исходные единицы измерения (за счёт квадратного корня) — это единственное отличие от *MSE*, которое имеет чисто интерпретационный, а не математический смысл;
- **квадратичный штраф**: ошибка в 10 единиц штрафует в **100 раз** сильнее ошибки в 1 единицу — *RMSE* непропорционально чувствителен к большим отклонениям;
- значение, минимизирующее *MSE* на выборке — **среднее арифметическое**, отсюда прямая связь: обычная линейная регрессия по МНК (метод наименьших квадратов) — это в точности минимизация *MSE*;
- математически всегда верно: **$RMSE \geq MAE$** для любого набора ошибок (следствие неравенства Йенсена / QM-AM неравенства), причём равенство достигается только тогда, когда все ошибки по модулю равны между собой.

4. Почему модели могут ранжироваться по-разному

Раз *RMSE* непропорционально штрафует крупные отклонения, а *MAE* — нет, **сравнение двух разных моделей** по этим двум метрикам может дать противоположные ответы. Продемонстрируем это на проверенном численном примере.

Модель А делает десять предсказаний, в каждом ошибка ровно 1 (много одинаковых мелких ошибок).

Модель В делает девять предсказаний идеально точно, но в одном случае ошибается на 9 (почти всегда точна, но с редким крупным промахом).

```
errors_A = np.array([1]*10, dtype=float)
errors_B = np.array([0]*9 + [9], dtype=float)
```

Проверенный результат:

Модель	MAE	RMSE
А (десять ошибок по 1)	1.0000	1.0000
В (девять точных + одна ошибка в 9)	0.9000	2.8460

Модель А имеет **более низкий RMSE** ($1.0 < 2.846$), но **более высокий MAE** ($1.0 > 0.9$), чем модель В — ровно тот парадокс, о котором спрашивают на собеседовании.

Интерпретация: модель А «в среднем» ошибается сильнее (MAE выше — она реже бывает идеально точной), но её ошибки равномерно распределены и никогда не бывают экстремальными. Модель В почти всегда идеальна, но иногда сильно промахивается — и именно этот единичный крупный промах непропорционально раздувает RMSE. Отсюда практический вывод: **если для бизнеса критичны именно редкие катастрофические ошибки (просадка склада, недооценка спроса в пиковый день) — ориентируйтесь на RMSE; если критична типичная, «средняя по больнице» точность прогноза — на MAE.**

5. R^2 (коэффициент детерминации)

$$R^2 = 1 - SS_{\text{res}} / SS_{\text{tot}}$$

$$SS_{\text{res}} = \sum (y_i - \hat{y}_i)^2 \quad \text{— сумма квадратов остатков модели}$$

$$SS_{\text{tot}} = \sum (y_i - \bar{y})^2 \quad \text{— сумма квадратов отклонений от среднего}$$

Интуиция: SS_{tot} — это ошибка тривиального *baseline*-предсказателя, который для каждого объекта выдаёт просто среднее значение таргета $\bar{y}$. R^2 сравнивает вашу модель именно с этим *baseline*:

- $R^2 = 1$ — модель предсказывает идеально ($SS_{\text{res}} = 0$);
- $R^2 = 0$ — модель работает ровно так же, как если бы вы всегда предсказывали среднее ($SS_{\text{res}} = SS_{\text{tot}}$);
- $R^2 < 0$ — модель работает хуже, чем тривиальное предсказание среднего.

Почему R^2 может быть отрицательным — частая путаница

В отличие от Accuracy или Precision, у R^2 нет нижней границы в 0. Формула $1 - SS_{\text{res}}/SS_{\text{tot}}$ может уйти сколь угодно далеко в минус, если SS_{res} намного превышает SS_{tot} — это происходит, когда модель систематически ошибается сильнее, чем просто «не знать ничего и говорить среднее». На обучающей выборке для классической линейной регрессии, обученной МНК, R^2 гарантированно ≥ 0 (модель по построению минимизирует SS_{res} и не может проиграть тривиальному *baseline* на тех же данных). Но на **новой (тестовой/продовой) выборке** — гарантий никаких: переобученная модель, модель с перепутанным знаком коэффициента,

модель, экстраполирующая за пределы обучающего диапазона, легко даёт R^2 глубоко в минусе.

Проверенный численный пример:

```
y_true      = [10, 12, 9, 11, 10.5, 9.5, 11.5, 10.2, 9.8, 10.8]
y_pred_bad  = [15, 5, 14, 4, 16, 3, 17, 2, 18, 1]      # явная ошибка
y_baseline  = [ȳ, ȳ, ..., ȳ]                        # всегда среднее
```

	SS	R^2
SS_tot (дисперсия данных)	7.6210	—
SS_res плохой модели	481.2700	-62.1505
baseline (всегда среднее)	= SS_tot	0.0000

R^2 плохой модели — **минус 62**. Это не опечатка и не баг: модель в среднем ошибается настолько сильнее тривиального прогноза, что коэффициент детерминации улетает далеко за -1 . Ручной расчёт $1 - SS_{res}/SS_{tot} = 1 - 481.27/7.621 = -62.15$ сходится с библиотечным `sklearn.metrics.r2_score` — формула подтверждена.

Правильный ответ на вопрос « $R^2 = -0.3$, что это значит?» — модель работает **хуже**, чем если бы вы просто всегда предсказывали среднее значение таргета. Не «объясняет -30% дисперсии» (у отрицательной величины нет физической интерпретации доли дисперсии) и не «переобучилась» (это возможная, но не единственная и не гарантированная причина — с тем же успехом это может быть банально неверно выбранная модель или ошибка в знаке коэффициента).

6. Сводная таблица выбора метрики

Критерий	MAE	RMSE	R^2
Единицы измерения	исходные единицы таргета	исходные единицы таргета	безразмерная (относительная)
Штраф за большие ошибки	линейный	квадратичный (сильный)	косвенно квадратичный (через SS_res)

Критерий	MAE	RMSE	R ²
Устойчивость к выбросам	высокая	низкая	низкая (наследует от SS_res)
Оптимальный константный предиктор	медиана	среднее	среднее (по определению)
Интерпретируемость для бизнеса	высокая («в среднем ошибаемся на X рублей»)	средняя (единицы те же, но смысл величины менее прямой)	высокая для сравнения моделей между собой, но требует осторожности с отрицательными значениями
Когда предпочесть	нужна устойчивость к аномалиям, “типичная” ошибка	критичны редкие крупные промахи	нужно сравнить модель с тривиальным baseline / со степенью объяснения дисперсии

7. Связь с вашим стеком (MarketPulse)

В проекте MarketPulse при обучении модели направления цены вы используете классификацию (LogReg на `target = 1` если цена выросла), но регрессионные метрики всплывут, если вы будете оценивать качество предсказания **самой волатильности** (`rolling_volatility` как непрерывная величина) или ошибку прогноза цены как таковой. Там же будет уместно решить: если вас интересует устойчивость к редким резким скачкам цены (flash crash) — RMSE специально «увидит» такие промахи сильнее; если интересна типичная точность прогноза в спокойном рынке — MAE честнее отразит повседневное качество модели.

Ключевые тезисы

1. MAE — линейный штраф, устойчив к выбросам, оптимум — медиана.
 2. RMSE — квадратичный штраф, чувствителен к выбросам, оптимум — среднее; всегда $RMSE \geq MAE$.
 3. Две модели могут ранжироваться противоположно разными метриками — это не ошибка, а следствие разной чувствительности к распределению ошибок (доказано численным примером выше).
 4. R^2 сравнивает модель с тривиальным baseline «всегда предсказывать среднее»: $R^2=0$ — равенство с baseline, $R^2=1$ — идеал, $R^2<0$ — модель хуже baseline, и снизу это значение **не ограничено**.
 5. Отрицательный R^2 на обучающей выборке для честной линейной регрессии практически невозможен; на тестовой/продовой — вполне реален и обычно сигнализирует о серьёзной проблеме модели, а не просто о «слабом качестве».
-

Вопросы для самопроверки

1. Постройте свой собственный пример (не совпадающий с примером выше), где у Модели X ниже RMSE, но выше MAE, чем у Модели Y.
 2. Почему RMSE не может быть меньше MAE ни при каком наборе ошибок? (Подсказка: подумайте про случай, когда все ошибки равны по модулю.)
 3. Модель показала $R^2 = 0.85$ на обучающей выборке и $R^2 = -1.2$ на тестовой. Какой диагноз наиболее вероятен и почему это не противоречит тому, что R^2 на трейне не может быть отрицательным для МНК-регрессии?
 4. Чем предсказание, минимизирующее MAE (медиана), принципиально отличается от предсказания, минимизирующего MSE (среднее), на выборке с сильно скошенным распределением (например, доходы клиентов)?
-

Разбор на собеседовании

Вопрос интервьюера	Эталонный ответ
«У модели A ниже RMSE, но выше MAE, чем у модели B. Что это означает?»	RMSE сильнее штрафует крупные отклонения, чем MAE. Модель A, вероятно, делает больше мелких ошибок, но реже допускает катастрофические промахи; модель B чаще точна, но иногда сильно ошибается — и этот редкий крупный промах непропорционально раздувает её RMSE. Выбор метрики должен зависеть от того, что дороже бизнесу: типичная точность (MAE) или отсутствие редких катастрофических ошибок (RMSE).
«Может ли R^2 быть отрицательным? Что это значит?»	Да. R^2 сравнивает модель с тривиальным baseline «всегда предсказывать среднее значение таргета». $R^2=0$ означает точное совпадение с этим baseline, отрицательный R^2 означает, что модель работает хуже этого тривиального прогноза — и снизу значение не ограничено.
«Почему у линейной регрессии, обученной МНК, R^2 на трейне практически никогда не бывает отрицательным?»	Потому что МНК по построению минимизирует SS_{res} (сумму квадратов остатков), а минимальное достижимое значение SS_{res} не может превышать SS_{tot} — ведь константная модель (предсказание среднего) сама является допустимым (хоть и не оптимальным) решением задачи минимизации МНК. На новых данных этой гарантии уже нет.
«В каком случае вы выберете MAE вместо RMSE при обучении модели прогноза спроса?»	Если в данных есть редкие, но легитимные экстремальные значения (распродажи, аномальные дни), которые не должны доминировать над обучением модели на “типичные” дни — MAE устойчивее к таким выбросам и не позволит одному аномальному дню перекосить всю модель.

Мостик к Части 3: Регрессионные метрики измеряют «насколько далеко» предсказанное число от истинного. В классификации такой прямой аналог

не работает — там важна не величина ошибки, а её тип (ложноположительная vs ложноотрицательная). В следующей части разберём *confusion matrix*, *Precision/Recall/F1/F β* и почему *Accuracy* может обманывать даже опытного инженера при сильном дисбалансе классов.

Пиши «Отлично» — и перейдём к Части 3.