

ЧАСТЬ 3. Confusion Matrix, Precision/Recall/F1/Fβ и ловушка Accuracy

Цель: уметь по одной табличке 2×2 восстановить любую метрику классификации, объяснить бизнес-смысл каждой из них и с ходу назвать пример, где Accuracy формально «хорошая», а модель — бесполезна.

1. Confusion Matrix (матрица ошибок)

Для бинарной классификации все возможные исходы сравнения предсказания $\hat{y}$ с истинной меткой y укладываются в четыре ячейки:

	Предсказан 1 (Positive)	Предсказан 0 (Negative)
Истина 1	TP (True Positive)	FN (False Negative)
Истина 0	FP (False Positive)	TN (True Negative)

Терминология из статистики, которая иногда всплывает на собеседовании отдельно:

- **FP — ошибка I рода** (ложная тревога: сказали «да», хотя было «нет»);
- **FN — ошибка II рода** (пропуск цели: сказали «нет», хотя было «да»).

Все метрики классификации, о которых пойдёт речь, — это разные способы «свернуть» четыре числа TP, TN, FP, FN в одно, каждый со своим акцентом на то, какая из ошибок дороже.

2. Accuracy и её парадокс

$$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$

Доля верных ответов среди всех предсказаний — самая интуитивная метрика и самая опасная при дисбалансе классов.

Проверенный численный пример. 1000 транзакций, из них 990 легитимных и 10 мошеннических (1% — типичный порядок для реального антифрода).

«Модель», которая **всегда** предсказывает «не фрод», не видя данных вообще:

Метрика	Значение
Accuracy	0.9900
Precision	0.0000
Recall	0.0000

99% точности — и при этом модель не поймала вообще ни одного мошенника. Это не гипотетический крайний случай, а прямое следствие формулы: при доле положительного класса p , Accuracy константного «всегда 0»-классификатора равна $1 - p$ — чем реже случается целевое событие, тем выше будет казаться Accuracy у модели, которая полностью его игнорирует. **Правило для собеседования:** Accuracy — осмысленная метрика только при сбалансированных классах (или близко к тому); при сильном дисбалансе она систематически завышает впечатление о качестве.

3. Precision (точность)

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

«Из всех объектов, которые модель назвала положительными — какая доля действительно положительна?» Precision отвечает за **цену ложной тревоги (FP)**.

Когда Precision критичен: рассылка дорогих печатных каталогов, блокировка карты клиента как подозрительной, показ рекламы узкому таргетированному сегменту — везде, где ложное срабатывание стоит реальных денег или раздражает добросовестного пользователя.

4. Recall (полнота, он же Sensitivity, True Positive Rate)

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

«Из всех действительно положительных объектов — какую долю модель нашла?» Recall отвечает за **цену пропуска (FN)**.

Когда Recall критичен: медицинский скрининг (пропущенная опухоль стоит несравнимо дороже лишнего направления на дополнительное

обследование), антифрод (пропущенная крупная мошенническая транзакция может стоить компании больше, чем сотня ложных блокировок), поиск дефектов на производственной линии.

Ключевая связь: *Precision* и *Recall* обычно находятся в обратной зависимости — при понижении порога классификации (модель охотнее говорит «1») *Recall* растёт (ловим больше положительных), а *Precision* падает (растёт число ложных срабатываний), и наоборот. Полная геометрия этого компромисса — в Части 4 (PR-кривая).

5. F1-score: почему гармоническое, а не арифметическое среднее

$$F1 = 2 \cdot Precision \cdot Recall / (Precision + Recall)$$

Это гармоническое среднее *Precision* и *Recall*. Возникает закономерный вопрос: почему не просто $(Precision + Recall) / 2$?

Проверенный численный пример. Возьмём вырожденный случай:

Precision = 1.0, *Recall* $\approx$ 0.0001 (модель почти никогда не срабатывает, но когда срабатывает — всегда права; классический “трусливый” классификатор).

Способ усреднения	Значение
Арифметическое среднее $(P+R)/2$	0.5000
Гармоническое среднее (F1)	0.0002

Арифметическое среднее говорит «модель на 50% хороша» — абсурдный вывод для классификатора, который практически ничего не находит.

Гармоническое среднее сильно штрафует за то, что хотя бы одна из двух величин близка к нулю — это его ключевое математическое свойство: гармоническое среднее двух чисел всегда $\leq$ их арифметического среднего, и разрыв тем больше, чем сильнее числа отличаются друг от друга. F1 корректно отражает: модель, которая не находит почти ничего, — плохая модель, независимо от того, насколько точны её редкие срабатывания.

6. F β -мера: взвешенное гармоническое среднее

F1 придаёт *Precision* и *Recall* равный вес — но бизнес-контекст редко симметричен. Общая формула:

$$F\beta = (1 + \beta^2) \cdot \text{Precision} \cdot \text{Recall} / (\beta^2 \cdot \text{Precision} + \text{Recall})$$

Интерпретация параметра β :

- $\beta = 1$ — F1, равный вес Precision и Recall;
- $\beta < 1$ (например, $\beta = 0.5$) — больший вес Precision (штрафуем за ложные срабатывания сильнее);
- $\beta > 1$ (например, $\beta = 2$) — больший вес Recall (штрафуем за пропуски сильнее) — именно такая настройка типична для медицинского скрининга, где цена пропущенного случая заболевания несопоставимо выше цены лишней перепроверки.

Проверенный численный пример на асимметричных Precision и Recall (Precision = 0.6429, Recall = 0.9000 — типичная картина классификатора с низким порогом отсеечения, настроенного «ловить всё»):

β	$F\beta$	Комментарий
0.5	0.6818	ближе к Precision (0.6429) — штрафует за низкую точность
1.0	0.7500	ровно посередине между гармоническими весами
2.0	0.8333	ближе к Recall (0.9000) — вознаграждает высокую полноту

Видно наглядно: чем больше β , тем ближе итоговое значение к Recall и тем меньше модель штрафует за посредственную Precision. Это прямой математический механизм того, что в задании про медицинский скрининг с $\beta=2$ правильный ответ — «минимизировать количество FN» (пропусков): формула буквально придаёт квадратичный вес $\beta^2=4$ именно Precision в знаменателе, ослабляя относительный вклад пропусков (FN сидит только в Recall) в итоговый штраф.

7. Полный воркед-пример (сквозной расчёт вручную и сверка с sklearn)

20 транзакций: 10 истинно мошеннических, 10 легитимных.

TP = 7 (мошенничество, поймано)
 FN = 3 (мошенничество, пропущено)
 TN = 7 (легитимная, верно пропущена)
 FP = 3 (легитимная, ложно заблокирована)

Метрика	Ручной расчёт	sklearn
Precision	$7/(7+3) = 0.7000$	0.7000
Recall	$7/(7+3) = 0.7000$	0.7000
F1	$2 \cdot 0.7 \cdot 0.7 / (0.7 + 0.7) = 0.7000$	0.7000
Accuracy	$(7+7)/20 = 0.7000$	0.7000

Здесь Precision и Recall случайно совпали (симметричная матрица ошибок), поэтому все $F\beta$ дают одно и то же значение 0.7 — хороший тест-кейс для проверки корректности реализации формул (если у вас $F\beta$ -функция написана руками, симметричный случай — быстрая sanity-проверка перед тем, как переходить к асимметричным данным).

8. Бизнес-таблица выбора метрики

Сценарий	Что дороже	Что оптимизировать
Антифрод (блокировка карты)	FP раздражает клиента, но не смертельно; крупный пропущенный фрод — прямые убытки	Recall или $F\beta$, $\beta > 1$
Спам-фильтр	FP (важное письмо в спаме) хуже, чем FN (спам в инбоксе)	Precision или $F\beta$, $\beta < 1$
Медицинский скрининг	Пропуск диагноза (FN) может стоить жизни	Recall или $F\beta$, $\beta = 2$ и выше
Рассылка дорогих печатных каталогов	Каждый FP — прямые деньги на ветер	Precision
Модерация контента (жёсткий фильтр)	Зависит от политики — часто симметрично	F1

Ключевые тезисы

1. Все метрики классификации — это разные функции от четырёх чисел TP , TN , FP , FN .
 2. Accuracy обманчива при дисбалансе классов: тривиальная константная модель может показать $Accuracy = 1 - p$, где p — доля редкого класса, не поймав ни одного целевого объекта.
 3. Precision отвечает за цену FP , Recall — за цену FN ; они обычно находятся в обратной зависимости при изменении порога.
 4. $F1$ — гармоническое, а не арифметическое среднее — потому что гармоническое среднее жёстко штрафует за то, что хотя бы одна из величин (P или R) близка к нулю, тогда как арифметическое среднее такую ситуацию маскирует.
 5. $F\beta$ — обобщение $F1$ с настраиваемым весом: $\beta > 1$ смещает акцент на Recall ($\beta = 2$ — классика медицинского скрининга), $\beta < 1$ — на Precision.
-

Вопросы для самопроверки

1. У вас 100 000 транзакций, из них 50 мошеннических. Модель, всегда предсказывающая «не фрод», получает какую Accuracy? Посчитайте точно.
 2. Постройте свой пример, где $Precision = 0.9$, $Recall = 0.1$, и вручную посчитайте $F1$, $F0.5$ и $F2$. Убедитесь, что $F0.5 > F1 > F2$ (в эту сторону, потому что здесь именно Precision высок, а не Recall).
 3. Почему для задачи «найти как можно больше потенциальных мошенников, даже ценой большого числа ложных проверок» неверно оптимизировать $F0.5$?
 4. Есть ли ситуация, где Precision и Recall совпадают, но матрица ошибок при этом не симметрична ($TP \neq TN$ или $FP \neq FN$)? Приведите числовой пример или объясните, почему это невозможно.
-

Разбор на собеседовании

Вопрос интервьюера	Эталонный ответ
«У вас 1% положительного класса, слабая модель показывает Ассигасу 99%. Хорошая ли это модель?»	Нет — при доле положительного класса 1% даже тривиальная модель, всегда предсказывающая «отрицательный класс», получит Ассигасу 99%, не поймав ни одного целевого объекта. Ассигасу здесь бессмысленна; нужно смотреть Precision/Recall/F1 или PR-AUC.
«Почему F1 — гармоническое среднее, а не арифметическое?»	Гармоническое среднее сильно штрафует ситуацию, когда одна из величин (Precision или Recall) близка к нулю — в отличие от арифметического среднего, которое такую асимметрию сглаживает и может дать обманчиво высокое значение даже для практически бесполезной модели.
«Вы настраиваете модель для медицинского скрининга и используете Fβ с β=2. Какое поведение вы поощряете?»	Минимизацию FN (пропусков) сильнее, чем минимизацию FP: $\beta^2=4$ в знаменателе формулы ослабляет относительный вес Precision, отдавая приоритет Recall — что соответствует бизнес-логике «лучше лишний раз перепроверить здорового, чем пропустить больного».
«В чём разница между ошибкой I и II рода применительно к Precision и Recall?»	Ошибка I рода (FP) снижает Precision, ошибка II рода (FN) снижает Recall — это два независимых канала ошибки, которые нельзя одновременно минимизировать без компромисса, задаваемого порогом классификации.

Мостик к Части 4: Все метрики этой части считаются при **фиксированном пороге** классификации (обычно 0.5). Но порог — это выбор инженера, а не свойство модели. В следующей части разберём ROC-AUC и PR-AUC — метрики, которые оценивают модель **по всем порогам сразу**, почему при сильном дисбалансе ROC-AUC может «врать», и разберём трюк с монотонным преобразованием вероятностей, который проверяется в вопросе про модель с ROC-AUC = 0.2.

Пиши «Отлично» — и перейдём к Части 4.